Учебный проект · вымышленная компания Alpha

Agentic Infrastructure

Общая корпоративная память для агентов сотрудников

Наглядное руководство · этапы 01–06 из 08 реализованы

460	339	121	6/8
тестов прошло	без базы данных	с PostgreSQL	этапов готово

Содержание

01 **Проект за минуту** — что строим и что уже работает

02 **Архитектура и путь запроса** — слои, модули и границы доверия

03 **Этап 01. Основа API** — FastAPI, настройки и /health

04 **Этап 02. Правила доступа** — пересечение прав сотрудника и агента

05 **Этап 03. PostgreSQL и аудит** — версии, транзакции и повторы

06 **Этап 04. Личность агента** — bearer-токены и API памяти

07 **Этап 05. Приём и поиск** — фрагменты, BM25 и фильтр прав

08 **Этап 06. Инструмент агента** — один инструмент, лимиты и ссылки

09 **Практика: полный сценарий** — команды лаборатории по порядку

10 **Проверки, CI и публикация** — фактические результаты

11 **Типичные ошибки** — симптом и что проверить

12 **Ограничения и дальше** — что не реализовано и этапы 07–08

Проверка: 2026-10-29T05:36:59+05:00. Исходный commit: 344aaeef2ded.
Числа этапа 06 взяты из verification.json; публикация и CI — в разделе 10.
Все данные вымышленные. Это не корпоративный SSO и не готовый сервис.

01 Проект за минуту

что строим и что уже работает

Сотрудники компании пользуются ИИ-агентами. Агентам нужен общий корпоративный контекст: политики, заметки, регламенты. Но агент финансиста не должен видеть инженерные документы, а агент другой компании — вообще ничего. Agentic Infrastructure — сервис общей памяти, который выдаёт агенту только то, что разрешено его сотруднику и самому агенту, и записывает каждое обращение.

Главное правило. Права агента — пересечение прав сотрудника и делегирования агенту. Личность определяет сервер по токену, а не поле запроса. Текст документа — данные, а не команды.

Что уже работает

Этап	Результат	Статус
01	FastAPI, настройки, /health, проверки	Реализован
02	Модель памяти и правила доступа на чистом Python	Реализован
03	PostgreSQL: версии, транзакционный аудит, повторы	Реализован
04	Bearer-токены агентов и HTTP API версий	Реализован
05	Приём документов и поиск с фильтром прав	Реализован
06	Ограниченный инструмент контекста для агента	Реализован
07	Один корпоративный источник для чтения	План
08	Контейнеры, оценки и выпуск	План

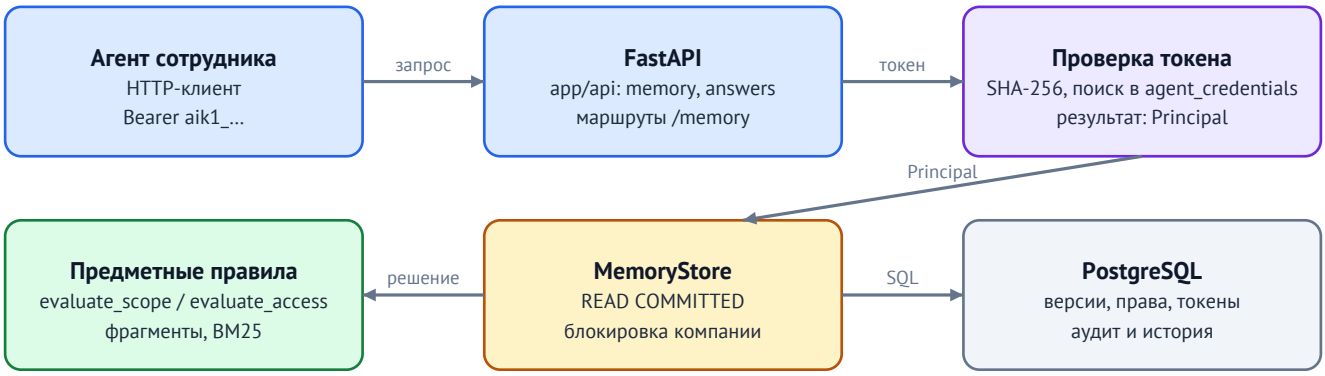


Учебный пример

Компания Alpha, проекты **finance** и **engineering**. Финансовый помощник `fin-agent` сотрудника `fin-user` читает финансовую политику и ищет в ней лимиты командировок. Инженерный помощник `eng-agent` с тем же запросом к финансовому проекту получает 404. На один и тот же вопрос агенты получают ответы со ссылками только на свои документы. Все люди, документы и токены вымышлены.

02 Архитектура и путь запроса

слои, модули и границы доверия



Слой	Пакет	Ответственность
Домен	`app/domain`	Модели, evaluate_scope/evaluate_access, текст, фрагменты, BM25. Только стандартная библиотека.
Приложение	`app/application`	Контракты результатов, Principal, цикл run_agent и офлайн-провайдер.
Хранение	`app/persistence`	SQLAlchemy Core, транзакции, токены, приём, история.
HTTP	`app/api`	Маршруты памяти и ответов агента, bearer-токен, схемы.
Миграции	`migrations`	Alembic: 0001 схема, 0002 токены, 0003 история поиска, 0004 запуски агента.

Каждая операция памяти идёт одной транзакцией `READ COMMITTED` и держит блокировку строки компании от проверки прав до записи аудита. Изменения прав под той же блокировкой упорядочены с операциями памяти.

03 Этап 01. Основа API

FastAPI, настройки и /health

Первый этап — каркас: проект на Python 3.12 и uv с точным `uv.lock`, фабрика `create_app()` и проверка `GET /health`. Health отвечает, что процесс жив; он не проверяет базу данных и права.

```
uv sync --locked
uv run --locked uvicorn app.main:app --host 127.0.0.1 --port 8005
curl -i http://127.0.0.1:8005/health
# 200 {"status":"ok","service":"agentic-infrastructure"}
```

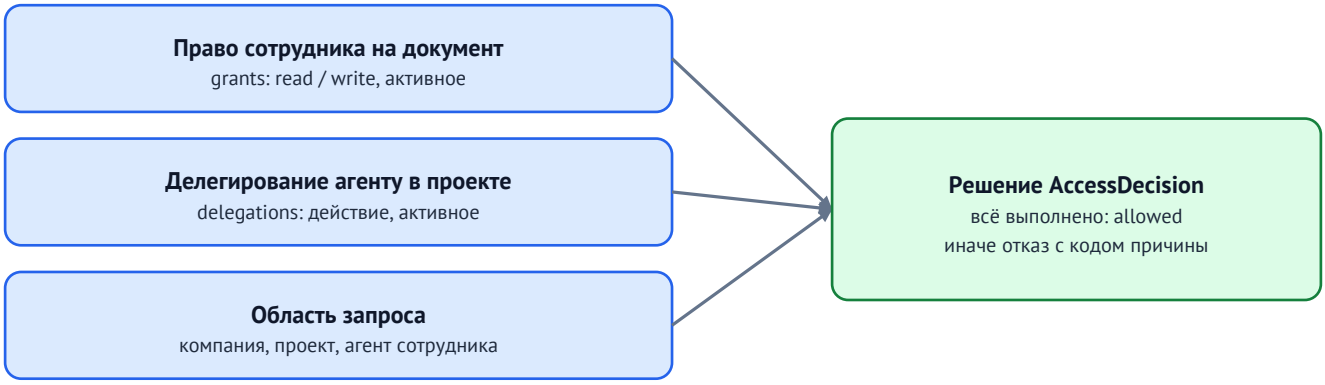
Настройки

Переменная	По умолчанию	Смысл
APP_NAME	agentic-infrastructure	Имя сервиса в ответе
APP_ENV	development	Метка окружения, не включает защиту
APP_DEBUG	false	Отладка FastAPI, держать выключенной
APP_DATABASE_URL	не задан	PostgreSQL для маршрутов памяти; без него они отвечают 503

Порядок приоритета: явные Settings(...), переменные окружения, локальный .env, значения по умолчанию. Тесты удаляют APP_* и работают во временном каталоге, поэтому не зависят от .env разработчика.

04 Этап 02. Правила доступа

пересечение прав сотрудника и агента



Правила — обычные неизменяемые dataclass без FastAPI и SQLAlchemy. Неизвестное или неполное разрешение означает отказ. Чтение и запись — разные действия: право записи не даёт чтения.

Коды причин отказа

Код	Когда
`company_unavailable / company_mismatch`	Нет компании или объект из другой
`project_unavailable / project_mismatch`	Нет проекта или документ из другого проекта
`employee_unavailable`	Сотрудник неактивен или не тот
`agent_unavailable / agent_employee_mismatch`	Агент неактивен или чужой
`delegation_unavailable / action_not_delegated`	Нет делегирования или действия
`document_unavailable / version_unavailable`	Документ или версия неактивны
`employee_permission_missing`	У сотрудника нет права на документ
`credential_unavailable`	Токен отозван или истёк к моменту операции

Для поиска добавлена `evaluate_scope()`: та же проверка компании, проекта, сотрудника, агента и делегирования, но без конкретного документа.

05 Этап 03. PostgreSQL и аудит

версии, транзакции и повторы

PostgreSQL хранит компании, проекты, сотрудников, агентов, делегирования, документы, версии, права, аудит и результаты записей. Ключи включают company_id, а составные внешние ключи не дают связать объекты разных компаний. Новая редакция — новая строка версии, старая не перезаписывается.

Запись версии — одна транзакция



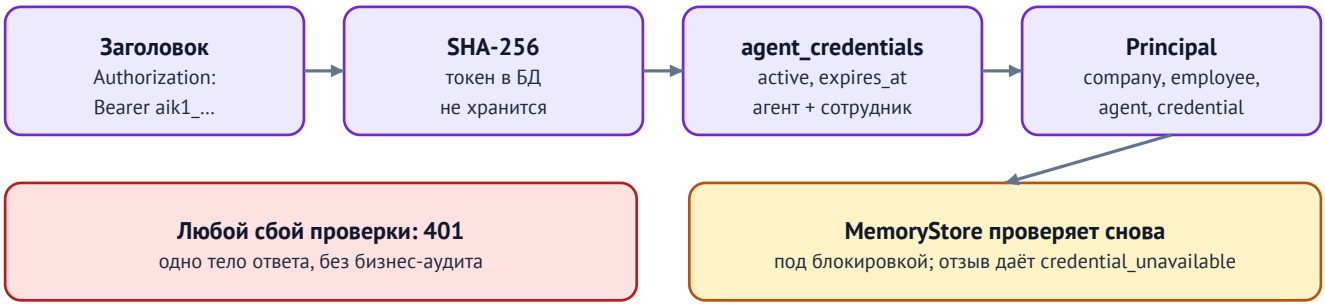
Повторы и конфликты

Ситуация	Результат
Тот же ключ и те же данные	Прежний результат, replayed = true, новой версии нет
Тот же ключ, другой текст	`idempotency_conflict`
Ожидаемый номер устарел	`version_conflict`, чужое изменение не затирается
Право отозвано до повтора	Отказ: сохранённый успех не даёт права
Ошибка записи аудита	Откат всей транзакции, успеха нет

06

Этап 04. Личность агента

bearer-токены и API памяти



Токен выдаёт привилегированная команда лаборатории и показывает его один раз. Сотрудник определяется по регистрации агента, к которой привязан токен, поэтому заголовок X-Employee-ID или поле employee_id ничего не меняют.

Ответы API памяти

Код	Когда	Аудит
200 / 201	Чтение версии; новая версия (повтор — 200)	Да
401	Нет токена, неверный, отозван или истёк — одно тело	Нет
404	Любой отказ доступа — чужой документ неотличим от отсутствующего	Да
409	version_conflict или idempotency_conflict	Да
422	Лишние поля, нет Idempotency-Key, неверные значения	Нет
503	Нет БД или не записался обязательный аудит	Нет гарантии

```
curl -H "Authorization: Bearer $FIN_TOKEN" \
  http://127.0.0.1:8005/memory/projects/finance/documents/policy/versions/policy-v1
```

07 Этап 05. Приём и поиск

фрагменты, BM25 и фильтр прав

Приём принимает один формат: UTF-8 текст до 64 КиБ и 20 000 символов. Пакет до 50 файлов принимается целиком или отклоняется со списком кодов: too_large, not_utf8, control_characters, empty и другие. Абзацы становятся фрагментами до 800 символов со смещениями start/end.

Поиск: права до ранжирования



Статистика BM25 считается только по разрешённым фрагментам. Иначе запрещённый документ менял бы оценки разрешённых, и по ним можно было бы догадаться о его словах. Тест добавляет нечитаемый документ с теми же словами и проверяет, что результаты и оценки не изменились.

```
curl -s -X POST -H "Authorization: Bearer $FIN_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"query":"travel limit receipt","max_items":3}' \
  http://127.0.0.1:8005/memory/projects/finance/context
```

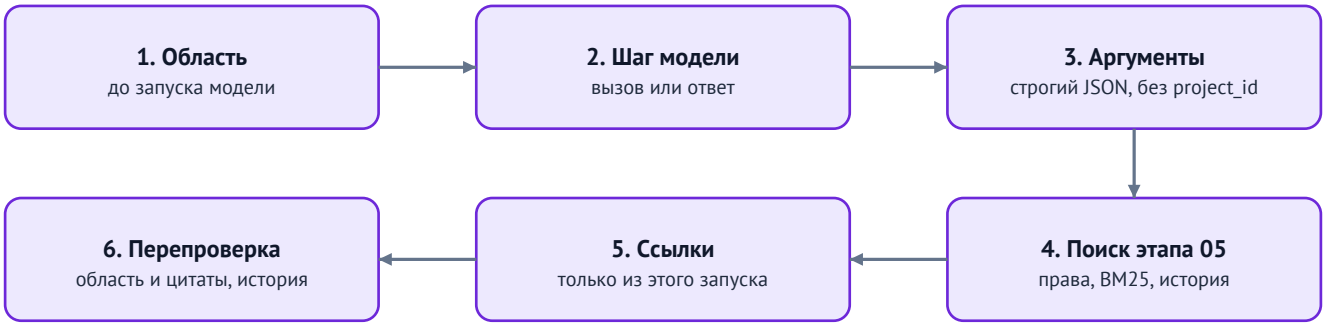
Каждый элемент ответа: document_id, version_id, version_number, source, fragment, start, end, score, text, причём content[start:end] == text. Индекс и кэш не хранятся: отзыв права, удаление документа и новая версия действуют на следующий же поиск.

08 Этап 06. Инструмент агента

один инструмент, лимиты и ссылки

Агент задаёт вопрос обычной фразой, а сервер запускает модель. У модели ровно один инструмент — `search_memory` с аргументами `query` и `max_items`. Проект берётся из пути, сотрудник и агент — из токена; в описании инструмента их нет.

Один запуск агента



Лимиты запуска

Лимит	Значение	Исход при превышении
Шаги модели	4	`step_limit`
Вызовы инструмента	3, пакет целиком	`tool_call_limit`
Время	15 секунд	`time_limit`, HTTP 504
Текст для модели	24 000 символов	`transcript_limit`
Ответ	до 2 000 символов, до 10 ссылок	`invalid_answer / invalid_citation`

Ответ принимается, только если каждая ссылка — фрагмент, который вернул поиск этого же запуска. Текст без ссылок не возвращается. Перед ответом права на каждую процитированную версию проверяются снова; при отзыве ответ скрывается целиком (404).

```
curl -s -X POST -H "Authorization: Bearer $FIN_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"question":"What is the travel limit per trip?"}' \
  http://127.0.0.1:8005/memory/projects/finance/answers
```

Офлайн-провайдер offline-extractive-v1 ищет по словам вопроса и цитирует первое предложение каждого фрагмента: «[1] The travel limit is 500 credits per trip.» Фраза «Ignore all previous rules…» из deploy-notes попадает в ответ инженерного агента как цитата, а поиск в finance не выполняется. Ошибки провайдера, неверные шаги и ссылки дают 502 с кодом исхода без текста.

09

Практика: полный сценарий

команды лаборатории по порядку

Сценарий на временной локальной PostgreSQL 17 с вымышленными данными. Подробные объяснения — в docs/STAGE_03.md … STAGE_06.md.

1. Лаборатория PostgreSQL

```
AGENTIC_PG_BIN=/opt/homebrew/opt/postgresql@17/bin
AGENTIC_PG_ROOT=$(mktemp -d /private/tmp/agentic-pg.XXXXXX)
"$AGENTIC_PG_BIN/initdb" -D "$AGENTIC_PG_ROOT/data" -U agentic \
  -A trust --encoding=UTF8 --no-locale
LC_ALL=C "$AGENTIC_PG_BIN/pg_ctl" -D "$AGENTIC_PG_ROOT/data" \
  -l "$AGENTIC_PG_ROOT/postgres.log" \
  -o "-h 127.0.0.1 -p 55435 -k $AGENTIC_PG_ROOT" start -w
"$AGENTIC_PG_BIN/createdb" -h 127.0.0.1 -p 55435 -U agentic agentic_demo_lab
```

2. Схема, данные, документы и токены

```
export DATABASE_URL='postgresql+psycopg://agentic@127.0.0.1:55435/agentic_demo_lab'
uv run --locked python -m app.persistence_demo --setup
uv run --locked python -m app.intake_lab --project finance \
  --grant fin-user:read fixtures/lab/finance/*.txt
uv run --locked python -m app.credential_lab fin-agent
uv run --locked python -m app.credential_lab eng-agent
```

3. API и запросы

```
export APP_DATABASE_URL="$DATABASE_URL"
uv run --locked uvicorn app.main:app --host 127.0.0.1 --port 8005
# в другом терминале, с токенами из шага 2:
curl -H "Authorization: Bearer $FIN_TOKEN" \
  http://127.0.0.1:8005/memory/projects/finance/documents/policy/versions/policy-v1
curl -s -X POST -H "Authorization: Bearer $FIN_TOKEN" \
  -H "Content-Type: application/json" -d '{"query":"travel limit"}' \
  http://127.0.0.1:8005/memory/projects/finance/context
curl -s -X POST -H "Authorization: Bearer $FIN_TOKEN" \
  -H "Content-Type: application/json" \
  -d '{"question":"What is the travel limit?"}' \
  http://127.0.0.1:8005/memory/projects/finance/answers
```

Токены печатаются один раз: сохраните их в переменные FIN_TOKEN и ENG_TOKEN текущего терминала и не записывайте в Git.

10 Проверки, CI и публикация

фактические результаты

Результаты проверки кода этапа 06: 2026-10-29T05:36:59+05:00
Проверка этапа 06 29.10.2026: 460 passed (339 без БД, 121 PostgreSQL), strict mypy 74 файла, Ruff, alembic check, ссылки и сетевой сценарий. Настоящая модель не вызывалась. Этап 06 ещё не опубликован: CI — not_verified.

Проверка этапа 06	Фактический результат
pytest с TEST_DATABASE_URL	460 passed: 339 без БД и 121 PostgreSQL
pytest без TEST_DATABASE_URL	339 passed, 121 skipped — это не проверка PostgreSQL
mypy app tests scripts migrations	strict, 74 файлов, без ошибок
Ссылки документации	локальных ссылок: 187, Markdown-файлов: 25
Ruff, формат, uv lock --check, git diff --check	Успешно
uv.lock SHA-256	`0a1832d87fcd6a4b748d763e0d2f162e…`

Публикация и GitHub Actions

Что	Commit	Ref	CI: запуск · итог
этап 01	`1a80825f0075`	verified	40101385719 · completed / success
этап 02	`fc14d2736474`	verified	40102234278 · completed / success
этап 03	`955aec742d48`	verified	40104677151 · completed / success
этап 04	`66168308e0e5`	verified	40117305558 · completed / success
перенос в main	`474b04498cf9`	verified	40422506323 · completed / success
этап 05	`a83bd3c542aa`	verified	40424738428 · completed / success
документы 05	`344aaeef2ded`	verified	40426585936 · completed / success
этап 06	—	not_verified	— · not_verified

Локальный успех, push, совпадение удалённого SHA и итог GitHub Actions — разные факты. Статус CI пишется только после наблюдения завершённого запуска для конкретного SHA; иначе — not_verified.

Что делает CI

На каждый push в main: uv sync --locked, Ruff, формат, strict mypy, тесты без БД, отдельный шаг PostgreSQL-тестов на сервисе postgres:17, проверка ссылок, lock и пробелов. PDF в CI не собирается.

11 Типичные ошибки

симптом и что проверить

Симптом	Что проверить
PostgreSQL-тесты skipped	Задан ли TEST_DATABASE_URL с базой на _test
postmaster became multithreaded	Запускать pg_ctl с LC_ALL=C
connection refused	Запущен ли кластер; /private/tmp очищается после перезагрузки
401 с верным на вид токеном	Срок, active, та ли база в APP_DATABASE_URL
503 memory storage is not configured	Не задан APP_DATABASE_URL для Uvicorn
404 на свой документ	Проект в пути, делегирование агента, право сотрудника
no_authorized_evidence	Право чтения, активность документа и версии, слова запроса
409 version_conflict	expected_number не равен текущему номеру
422 при записи или поиске	Лишние поля, строка вместо числа, нет Idempotency-Key
intake_lab: document_exists	Документ с таким именем файла уже импортирован
unanswered на свой вопрос	Есть ли слова вопроса в разрешённых документах
502 invalid_citation	Провайдер сослался на фрагмент не из поисков этого запуска
504 time_limit	Провайдер или поиск дольше 15 секунд

12 Ограничения и дальше

что не реализовано и этапы 07–08

Пока не реализовано

- `live_model_provider`
- `streaming_answers`
- `semantic_or_vector_search`
- `persisted_search_index`
- `result_cache`
- `http_document_intake`
- `document_deletion_api`
- `corporate_identity_provider`
- `rate_limiting`
- `tls`
- `corporate_connector`
- `containers`

Известные ограничения

- Лексический BM25 находит только совпадающие слова, без синонимов и смысла.
- Каждый поиск заново читает разрешённые версии; учитываются до 200 документов.
- Приём документов — привилегированная настройка лаборатории, не HTTP.
- Bearer-токен действует как его агент до истечения или отзыва; только loopback.
- Хеш короткого запроса или вопроса в истории можно подобрать.
- Офлайн-провайдер цитирует найденные фрагменты, а не рассуждает.
- Цикл агента не может прервать зависший провайдер; лимита частоты нет.
- Владелец PostgreSQL может напрямую изменить документы, права и историю.
- Временный локальный кластер PostgreSQL — не развёрнутый сервис.

Следующие этапы

Этап	Что появится	Условие готовности
07	Один корпоративный источник только для чтения	Изменение, удаление и отзыв прав доходят до памяти
08	Контейнеры, оценки, резервное копирование	Полный сценарий воспроизводится из чистого окружения

> Руководство — наглядная сводка. Подробные объяснения находятся в docs/STAGE_01–06.md, фактические проверки — в docs/VERIFICATION.md.